

Rapport de Veille : Cybersécurité et Armement de l'IA (Mai 2026)

David LEGRAND

13 mai 2026

L'intelligence artificielle modifie rapidement les pratiques offensives en cybersécurité. Exploits zero-day assistés par IA, malwares mobiles intelligents, usage des LLM par des groupes étatiques et multiplication des APIs clandestines : ce rapport de veille présente plusieurs évolutions majeures observées en mai 2026 autour de l'armement de l'IA.

1. Premier exploit zero-day développé avec l'aide d'une IA

Le Google Threat Intelligence Group (GTIG) a identifié une campagne exploitant une faille zero-day dont le code semble avoir été généré par une IA.

Points clés

- La faille touche un outil d'administration open-source très utilisé.
- Elle permet de contourner l'authentification à deux facteurs (2FA).
- Le script présentait plusieurs indices typiques des LLM :
 - docstrings très détaillées ;
 - structure de code très propre ;
 - score CVSS inventé par le modèle.

Nature de la faille

La vulnérabilité repose sur une erreur de logique métier, un domaine dans lequel les IA génératives deviennent particulièrement efficaces.

2. PromptSpy : des malwares Android dopés à l'IA

Le malware PromptSpy utilise des modèles d'IA pour analyser l'écran de la victime en temps réel.

Capacités observées

- Détection du bouton « Désinstaller » pour le rendre inutilisable via un calque invisible.
 - Capture et reproduction de gestes biométriques.
 - Adaptation dynamique à l'interface utilisateur.
-

3. Usage des LLM par des groupes APT

Plusieurs groupes étatiques utilisent désormais les IA génératives pour accélérer leurs opérations offensives.

Exemples

- **APT45 (Corée du Nord)** : analyse de CVE et validation de PoC.
 - **APT27 / UNC2814 (Chine)** : recherche de failles réseau et outils de relais.
 - **Russie** : création de malwares intégrant du faux code généré par IA pour masquer leurs fonctions réelles.
-

4. Développement des “Shadow APIs”

Une étude du CISPÀ a identifié plusieurs APIs non officielles donnant accès à des modèles comme Gemini ou Claude.

Risques principaux

- Collecte des prompts et réponses des utilisateurs.
 - Fuites potentielles de données sensibles.
 - Dégradation de la qualité et de la sécurité des modèles utilisés.
-

Conclusion

L'intelligence artificielle réduit fortement le délai entre la découverte d'une vulnérabilité et son exploitation. Les attaquants s'appuient désormais sur des agents semi-autonomes capables d'automatiser des phases entières de reconnaissance et d'attaque.

Sources

- <https://thehackernews.com/2026/05/hackers-used-ai-to-develop-first-known.html>
- <https://korben.info/google-neutralise-la-premiere-cyber-attaque-massive-generee-par-une-ia.html>