



Mistral est-il vraiment open source ?

Décortiquer le continuum d'ouverture en IA

Agenda



Bloc 1 : Logiciel libre et standards ouverts



Bloc 2 : Le continuum d'ouverture en IA



Bloc 3 : Réglementaire + frugalité



Bloc 4 : Ollama, conclusion et twist final

Bloc 1 — Logiciel libre et standards ouverts

Pour comprendre « open source » en IA, il faut d'abord comprendre le logiciel libre traditionnel

Trois concepts clés : libertés, standards, interopérabilité


Les 4 libertés (FSF, Richard Stallman)

Liberté 0 : Utiliser

Liberté 1 : Étudier et modifier

Liberté 2 : Redistribuer

Liberté 3 : Redistribuer modifiée





Standards ouverts ≠ Logiciel libre

Un standard ouvert = une spécification commune que tout le monde peut respecter

USB, TCP/IP, HTTP, HTML

Universal Serial Bus



Maintenant, appliquons ça à l'IA...

Maintenant qu'on a ces concepts clés...

La question : « Comment appliquer ça à l'IA ? »


Parce qu'un modèle d'IA n'est pas qu'un programme

Un modèle d'IA $\neq$ Un programme classique

Logiciel : le code source explique tout

IA : son comportement vient de 3 composantes indépendantes

- Poids (paramètres appris)
- Recette d'entraînement (code + hyperparamètres)
- Données (le matériau brut)



Comment fabrique-t-on un modèle ? (analogie du gâteau)



POIDS
=
Le gâteau fini

RECETTE
=
Le processus (température, durée, ordre)

DONNÉES
=
Les ingrédients (farine, œufs, qualité)


Open weight vs Open source : la distinction critique

	Open weight	Open source
Poids	✓ Public	✓ Public
Recette + données	✗ Fermé	✓ Public
Libertés FSF	Liberté 0 seule	Libertés 0-3 ✓✓✓

« Filtre d'amour » : open weight te fait confiance au vendeur.
Open source te permet d'auditer toi-même.



Le continuum en 4 catégories



Pourquoi la distinction importe vraiment

Exemple 1 : Les données cachées

Imagine un modèle entraîné sur des données contaminées par la propagande d'un dictateur

Open weight seul : tu goûtes le gâteau, c'est bizarre, mais tu ne sais pas d'où ça vient

Open source : tu vois la recette et les ingrédients, tu repères la source contaminée



Erreurs méthodologiques révélées (cas Lucie)

OpenLLM France, janvier 2025

Lucie lancée en version inachevée, non censurée

Communauté a vu les erreurs et dénoncé

Forcé de corriger

Si Lucie était fermée : personne n'aurait jamais su




Comment les gouvernements définissent-ils « open source » ?

L'UE a répondu avec l'AI Act.

Et la réponse n'est pas celle qu'on attendrait...

Attention : 3 définitions différentes du mot « open source »

Contexte	Définition	Exigence sur les données
Marketing	Poids publiés, transparent-ish	Rien
AI Act (légal)	Licence libre + architecture publique + non monétisé	Un résumé du contenu (art. 53(1)(d))
OSAID (OSI)	Utiliser / étudier / modifier / redistribuer	Infos suffisantes pour reconstruire




Données d'entraînement — Marketing : rien | AI Act : un résumé du contenu | OSAID : de quoi reconstruire

L'Union européenne exempte les modèles « open source »

Article 2(12) : exemption pour open source (risque systémique allégé)

Mais : seuil à 10^{25} FLOPs (article 51(2))

Paradoxe : Llama-3 405B $\approx 3,8 \times 10^{25}$ FLOPs $\rightarrow$ au-dessus du seuil



La fausse bonne idée : local = plus écolo ?

Intuition : faire tourner un modèle chez moi, c'est plus écolo qu'une API cloud

Réalité : c'est plus compliqué



Quand est-ce que local devient compétitif ?



Pragmatisme

Local pas forcément mieux

API cloud pas forcément pire

L'intérêt de open weight : tu peux décider au cas par cas

Ollama : comment ça fonctionne ?

Plateforme MIT (code ouvert)

Catalogue exclusivement open weight + open source (zéro fermé/API)

3 modes : Local (CLI gratuit) / API (gratuit, limité) / Cloud Pro (20\$/mois)

Exemples : Llama, OLMo, Gemma, Llama Vision


[image manquante : slide19_ollama_screenshot.png]

Mistral est-il vraiment open source ?

Non. Mistral est open weight.

Pour être open source, il faudrait aussi publier les données et la recette d'entraînement.

« Open source » n'est pas une case qu'on coche : c'est un continuum, et c'est un choix.



Mais attends...

Le vrai dilemme : large choix ou souveraineté ?

OLLAMA (USA)

✓ Large catalogue
(dizaines de modèles open weight/source)

✗ RGPD : transfert hors UE
(infrastructure USA, article 44)

INFOMANIAK (Suisse)

✓ RGPD conforme
(adéquation UE, 100% infra suisse)

✗ Catalogue plus restreint
(8 modèles, dont Apertus — open source suisse)

Rarement les deux à la fois.

Questions ?