

Script oral — Mistral est-il vraiment open source ?

Aide-mémoire pour la présentation, slide par slide. Durée totale : 9 :30.

Slide 1 — Titre

Durée : 0s **Fin de slide :** 0 :00

(Rien à dire. L'image s'affiche, deux secondes de silence, puis j'enchaîne directement sur l'agenda.)

Slide 2 — Agenda

Durée : 15s Fin de slide : 0 :15

Aujourd'hui je vous emmène dans le monde de l'open, en quatre étapes. D'abord le logiciel libre et les standards ouverts. On continuera ensuite sur l'ouverture en IA. Puis un détour réglementaire et écologique. Et pour finir, si on a le temps, on évoquera Ollama.

Slide 3 — Bloc 1 : Logiciel libre et standards ouverts

Durée : 20s Fin de slide : 0 :35

Pour comprendre ce que “open source” veut dire pour l’IA, il faut d’abord repartir du logiciel libre classique. Trois mots à garder en tête : libertés, standards, interopérabilité.

Slide 4 — Les 4 libertés (FSF, Richard Stallman)

Durée : 45s **Fin de slide :** 1 :20

Très rapidement : on doit ça à Richard Stallman et à la Free Software Foundation, dans les années 80.

Le logiciel libre repose sur quatre libertés, numérotées de zéro à trois. Utiliser le programme comme on veut — quelle que soit sa nationalité, l'usage qu'on en fait, le but qu'on poursuit, on peut l'utiliser. L'étudier et le modifier, pour l'adapter à ses besoins — ce qui suppose d'avoir le code source, pas juste le binaire compilé. Le redistribuer. Et redistribuer ses propres modifications, grâce notamment à la licence GPL, qui impose de redistribuer le code source et les modifications.

Pour les retenir, pensez à une recette de cuisine. La liberté zéro, c'est manger le plat, ou en faire ce qu'on veut. La un, c'est lire la recette et la modifier — ajouter du sel, changer les quantités. La deux, c'est donner la recette à des amis. La trois, c'est donner votre propre version modifiée.

Une précision importante : libre ne veut pas dire gratuit. C'est une question de libertés d'action, pas de prix.

Linux en est un exemple bien connu, mais il y en a beaucoup d'autres : Firefox, Git, Python, GCC, et bien d'autres encore.

Slide 5 — Standards ouverts, différent du logiciel libre

Durée : 30s **Fin de slide :** 1 :50

Un standard ouvert, c'est différent du logiciel libre. On en parle pour des formats de fichiers, des protocoles de communication, des API. Un standard ouvert est publié et disponible pour tout le monde, sans restriction de licence ni de brevet — et il est maintenu par une communauté, pas par une seule entreprise.

On parle souvent d'interopérabilité : la capacité de systèmes différents à travailler ensemble. Prenez l'USB. Peu importe que vous branchiez un iPhone, un Samsung, un PC ou un Mac : tant que l'appareil respecte le standard, la connexion fonctionne. On se fiche du matériel derrière la prise — on ne demande jamais “comment ça marche à l'intérieur”, juste “est-ce que ça respecte le standard”.

Quelques exemples : TCP/IP pour Internet, HTML pour le web, PDF pour les documents. Ça donne la liberté d'interagir et de changer de fournisseur sans être bloqué. Pas forcément la liberté de modifier le code.

Slide 6 — Maintenant, appliquons ça à l'IA...

Durée : 20s Fin de slide : 2 :10

Avec ces concepts en tête, la question devient : comment ça s'applique à l'intelligence artificielle ? Parce qu'un modèle d'IA, ce n'est pas juste un programme.

Slide 7 — Un modèle d'IA n'est pas un programme classique

Durée : 40s **Fin de slide :** 2 :50

Pour un logiciel classique, le code source explique tout : un seul artefact concentre toute l'information.

Un modèle d'IA, c'est radicalement différent. Son comportement vient de trois choses indépendantes : les poids, appris pendant l'entraînement ; le code et le processus d'entraînement ; et les données sur lesquelles il a appris. Chacune peut être ouverte ou fermée indépendamment des deux autres — c'est ça qui crée tout un continuum, là où le logiciel classique ne connaît que deux cas : code disponible, ou pas.

Slide 8 — Comment fabrique-t-on un modèle ? (analogie du gâteau)

Durée : 40s **Fin de slide :** 3 :30

Pour visualiser ça, pensez à un gâteau.

- Les poids, c'est le gâteau fini — le résultat qu'on peut consommer.
- Le code et le processus d'entraînement, c'est la recette — la température, la durée, l'ordre des étapes.
- Les données, ce sont les ingrédients — la farine, les œufs, leur qualité.

Si vous n'avez que le gâteau fini, vous pouvez le manger. Mais vous ne savez ni comment il a été fait, ni comment le reproduire à l'identique.

Slide 9 — Open weight vs Open source : la distinction critique

Durée : 35s Fin de slide : 4 :05

Open weight, c'est je vous montre le gâteau fini, avec un bel emballage. Mais ni la recette, ni les ingrédients. Impossible de vérifier une allergie, un biais caché. Llama, Mistral, DeepSeek sont dans ce cas.

Open source, au sens strict, c'est je vous montre tout : le gâteau, la recette, les ingrédients. Vous pouvez utiliser, étudier, modifier, redistribuer.

Filtre d'amour : l'open weight repose sur une confiance aveugle envers celui qui a fabriqué le modèle. L'open source permet une confiance vérifiée.

Slide 10 — Le continuum en 4 catégories

Durée : 40s **Fin de slide :** 4 :45

Quatre catégories, de la fermeture totale à l'ouverture complète.

Fermé, API : GPT, Claude, Gemini — aucune composante accessible, juste un accès distant payant. Un choix stratégique valide, pas une tare.

Open weight : Llama, Mistral, DeepSeek — les poids sont publics, le reste non.

Open weight plus plus : gpt-oss, Gemma, Qwen — une documentation plus riche, mais toujours pas de reproduction indépendante possible.

Open source, au sens strict : OLMo, Apertus, Luciole — poids, code et données publiés, les quatre libertés s'appliquent réellement.

Et Mistral se situe ici, en open weight.

Slide 11 — Pourquoi la distinction importe vraiment

Durée : 35s **Fin de slide :** 5 :20

Un exemple concret. Imaginez un modèle entraîné sur des données contaminées par la propagande d'un régime autoritaire.

Avec l'open weight seul, vous constatez qu'une réponse est bizarre, mais impossible d'en trouver l'origine — même pas moyen d'auditer. Avec l'open source, vous avez accès aux données : vous voyez d'où vient le biais, et vous pouvez le corriger.

C'est comme une eau contaminée invisible dans la préparation. L'open weight, vous goûtez un résultat étrange sans savoir pourquoi. L'open source, vous repérez tout de suite la source contaminée. L'indépendance de penser dépend de la transparence de la fabrication.

Slide 12 — Erreurs méthodologiques révélées (cas Lucie)

Durée : 20s Fin de slide : 5 :40

Janvier 2025 : Lucie, le modèle français d'OpenLLM France, est lancée en version inachevée, avec des réponses parfois incohérentes. Parce que le projet était ouvert, la communauté a détecté les problèmes et forcé une correction rapide. Si Lucie avait été fermée, personne n'aurait jamais su.

L'ouverture permet la correction communautaire.

Slide 13 — Comment les gouvernements définissent-ils « open source » ?

Durée : 15s Fin de slide : 5 :55

Une question réglementaire se pose alors : comment les gouvernements définissent-ils “open source” ? L’Union européenne a répondu avec l’AI Act. Et la réponse n’est pas celle qu’on attendrait.

Slide 14 — Attention : 3 définitions différentes du mot « open source »

Durée : 25s Fin de slide : 6 :20

En fait, le mot “open source” recouvre trois définitions différentes : le marketing, l’AI Act, et l’OSAID. Et contrairement à ce qu’on pourrait croire, l’AI Act est plus léger que l’OSAID — il demande seulement un résumé des données d’entraînement, pas de les publier entièrement.

(Regardez le schéma : aucune des trois définitions ne recouvre exactement les deux autres.)

Slide 15 — L'Union européenne exempte les modèles « open source »

Durée : 40s **Fin de slide :** 7 :00

L'AI Act ne se contente pas de classer les systèmes par niveau de risque : il impose aussi des obligations propres aux gros modèles généralistes. Il y en a quatre : documenter la technique en détail, documenter à destination des fournisseurs en aval, respecter le droit d'auteur, et publier un résumé du contenu d'entraînement.

L'exemption pour les modèles open source ne porte que sur les deux premières — documentation technique et documentation aval. Le droit d'auteur et le résumé du contenu d'entraînement restent obligatoires, même open source.

Et cette exemption saute complètement si le modèle est monétisé, ou s'il dépasse le seuil de risque systémique : dix puissance vingt-cinq FLOPs. Llama-3 405B le dépasse largement.

Slide 16 — La fausse bonne idée : local = plus écolo ?

Durée : 25s Fin de slide : 7 :25

On pense souvent : faire tourner un modèle chez soi, c'est plus écolo qu'une API cloud. C'est plus compliqué que ça.

Imaginez une mini-piscine chez vous, utilisée une heure par semaine. Contre une piscine communautaire, utilisée par cinq cents personnes, vingt-quatre heures sur vingt-quatre. La communautaire est bien plus efficace.

Slide 17 — Quand est-ce que local devient compétitif ?

Durée : 20s Fin de slide : 7 :45

En dessous de 85% d'utilisation GPU, mieux vaut le cloud — batching, datacenter optimisé. Au-dessus, le local devient compétitif.

Il faut vérifier les chiffres réels. Pas supposer.

Slide 18 — Pragmatisme

Durée : 10s Fin de slide : 7 :55

(Enchaîner directement, sans pause.)

Le local n'est pas forcément mieux. Le cloud n'est pas forcément pire.
L'intérêt de l'open weight, c'est de pouvoir décider au cas par cas.

Slide 19 — Ollama : comment ça fonctionne ?

Durée : 20s Fin de slide : 8 :15

Ollama, c'est exclusivement de l'open weight et de l'open source — aucun modèle fermé. Trois façons de l'utiliser : en local gratuitement, via une API limitée, ou en Cloud Pro à vingt dollars par mois.

La monétisation, c'est l'infrastructure cloud. Pas les modèles.

Slide 20 — Mistral est-il vraiment open source ?

Durée : 20s Fin de slide : 8 :35

Alors, la réponse directe : non. Mistral est open weight, pas open source. Pour l'être vraiment, il faudrait publier aussi les données et la recette d'entraînement complète.

“Open source” n'est pas une case qu'on coche. C'est un continuum. Et c'est un choix.

Slide 21 — Mais attends...

Durée : 40s Fin de slide : 9 :15

(Ne pas précipiter — c'est le twist final.)

Vous vous dites peut-être : je vais utiliser Ollama Cloud, c'est open source, donc je suis indépendant.

(pause)

Sauf que l'infrastructure d'Ollama Cloud est hébergée aux États-Unis — un transfert de données hors Union européenne.

Il existe une alternative : Infomaniak, en Suisse, conforme RGPD. Mais son catalogue est plus restreint — huit modèles, dont Apertus, celui-là même dont je vous ai parlé tout à l'heure.

Le vrai dilemme : large choix, ou souveraineté. Rarement les deux à la fois.

(ton léger, un peu ironique) Eh merde.

L'indépendance technique, ce n'est pas la même chose que l'indépendance réelle.

Slide 22 — Questions ?

Durée : 15s **Fin de slide** : 9 :30

Voilà. Je vous laisse la parole.

Rappels de rythme

- **Transitions (3, 6, 13)** : dites vite, sans se précipiter au point de perdre l'auditoire.
- **Bloc 3 (14 à 18)** : le plus technique et le plus dense. Parler lentement, articuler.
- **Slide 21** : le twist final. Ne pas la bâcler — c'est elle qui laisse la dernière impression.